

Universidade Federal da Bahia Instituto de Matemática

Programa de Pós-Graduação em Ciência da Computação

APLICANDO REDES DE FUNÇÃO DE BASE RADIAL PARA DETECÇÃO DE NOVIDADES EM FLUXOS DE DADOS

Ruivaldo Azevedo Lobão Neto

QUALIFICAÇÃO DE MESTRADO

Salvador 03 de Abril de 2019

RUIVALDO AZEVEDO LOBÃO NETO

APLICANDO REDES DE FUNÇÃO DE BASE RADIAL PARA DETECÇÃO DE NOVIDADES EM FLUXOS DE DADOS

Esta Qualificação de Mestrado foi apresentada ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal da Bahia, como requisito parcial para obtenção do grau de Mestre em Ciência da Computação.

Orientador: Ricardo Araújo Rios

Salvador 03 de Abril de 2019

TERMO DE APROVAÇÃO

RUIVALDO AZEVEDO LOBÃO NETO

APLICANDO REDES DE FUNÇÃO DE BASE RADIAL PARA DETECÇÃO DE NOVIDADES EM FLUXOS DE DADOS

Esta Qualificação de Mestrado foi julgada adequada à obtenção do título de Mestre em Ciência da Computação e aprovada em sua forma final pelo Programa de Pós-Graduação em Ciência da Computação da Universidade Federal da Bahia.

Salvador, 03 de Abril de 2019

Prof. Dr. Ricardo Araújo Rios UFBA

RESUMO

Diversas aplicações industriais, científicas e comerciais produzem sequências de observações de forma contínua, teoricamente infinitas, denominadas fluxos de dados. O estudo da recorrência dos dados nesses fluxos permite a criação de modelos de aprendizagem. Contudo, as mudanças de comportamento na sequência de dados prejudicam a acurácia desses modelos. Essas mudanças são produzidas por agentes externos ainda desconhecidos para os modelos vigentes, por exemplo: mudanças no clima, novos interesses dos sujeitos envolvidos, desastres naturais, novas estratégias de investimento, etc. No âmbito do Aprendizado de Máquina (AM), diversas pesquisas têm sido realizadas para identificar e investigar essas variações nos fluxos de dados, definidas como mudanças de conceito (concept drift). A correta detecção das mudanças de conceito, permite que os modelos possam ser atualizados, a fim de refinar a predição, a compreensão do modelo e, possivelmente, atuar sobre os fenômenos que conduzem o fluxo de dados em análise. Apesar da existência de variados algoritmos para detecção de mudanças de conceito em fluxos de dados, a maioria utiliza uma estrutura de janelas e dependem da correta rotulação das amostras (paradigma supervisionado) para seu funcionamento. Este tipo de abordagem aumenta a complexidade dos algoritmos, os requisitos de processamento, e afetam o tempo para detecção e resposta. Neste trabalho, um novo algoritmo para detecção de mudanças de conceito em fluxos de dados baseado em redes de função de base radial é proposto. O método proposto é comparado com vários algoritmos amplamente utilizados na literatura, e os resultados mostram ...

Terminar. Incluir mais diferenciais e relatar os resultados.

Palavras-chave: Aprendizado de Máquina, Fluxos de Dados, Mudanças de Conceito, Redes de Função de Base Radial

ABSTRACT

Findo o resumo, traduzir para o abstract

Keywords: Machine Learning, Data Streams, Concept Drift, Radial Basis Function Networks

SUMÁRIO

Capítul	lo 1—Introdução	1
1.1 1.2	Contexto e Motivação	1
Capítul	lo 2—Revisão Bibliográfica	3
2.1 2.2	Considerações Iniciais	3
2.3	Mudança de Conceito	3
	2.3.1 Algoritmos para Detecção de Mudança de Conceito	4
2.4	2.3.2 Ferramentas	4
$\frac{2.4}{2.5}$	Trabalhos Relacionados	4
2.6	Considerações Finais	5
Capítul	lo 3—Plano de Pesquisa	7
3.1	Considerações Iniciais	7
3.2	Descrição do Problema	7
3.3	Considerações Finais	8
Capítul	lo 4—Experimentos Iniciais	Ĉ
4.1	Considerações Iniciais	G
4.2	Configuração dos Experimentos	6
4.3	Método de Pettitt	Ö
4.4	Redes de Função de Base Radial	10
4.5	Considerações Finais	10

LISTA DE FIGURAS

LISTA DE TABELAS

INTRODUÇÃO

1.1 CONTEXTO E MOTIVAÇÃO

Diversos processos industriais, científicos e comerciais produzem sequências, teoricamente infinitas, de observações ao longo do tempo, denominadas fluxos de dados. Exemplos incluem transações de cartões de crédito, sensores de temperatura, dados do mercado de ações, indicadores de saúde, etc (AGGARWAL et al., 2003).

Mudanças no contexto ou parâmetros desses processos, podem alterar o comportamento dos fluxos de dados ao longo do tempo, por exemplo: influência de notícias no mercado de ações, mudanças abruptas no clima, etc. Essas flutuações são chamadas de mudanças de conceito e geralmente identificam eventos de interesse, pois informam sobre fatores externos influenciando o processo gerador do fluxo. Enquanto nenhuma mudança é detectada, sabemos que o processo mantém-se estável e devidamente representado pelo modelo vigente.

A detecção dessas mudanças é importante em diversos cenários, como no monitoramento do fluxo de alimentação em uma caldeira industrial (Ang et al., 2013). Mudanças de conceito podem acontecer, pois a alimentação de combustível é um processo manual e não padronizado, que não é necessariamente suave e pode ter interrupções curtas. Além disso, cada operador pode ter hábitos diferentes. A alimentação da caldeira fora dos padrões devidos, pode oferecer risco à vida dos trabalhadores da indústria.

Existem diversos algoritmos para detectar mudança de conceito, sendo a maior parte baseado em modelos de aprendizagem supervisionados (GAMA et al., 2014). Estes algoritmos, baseiam-se na correta rotulagem dos dados para atualização do modelo e posterior classificação. No entanto, este paradigma enfrenta dificuldades quando os dados são produzidos em altas frequências e grandes volumes, tornando a espera por um rótulo correto inviável. Esta limitação motivou os pesquisadores a explorarem o paradigma não supervisionado, que não requer conhecimento prévio sobre os dados.

O aprendizado não supervisionado baseia-se em algoritmos de agrupamento de dados para extração e organização das observações, posicionando-as conforme medições de similaridade. Tais algoritmos consideram mudanças nas partições dos *clusters* um indicativo

2 INTRODUÇÃO

da ocorrência de mudança de conceito (AGGARWAL et al., 2003). Isto é, a partição produzida no instante t é comparada com a t-1, obtendo-se uma medida de divergência, utilizada para indicar a ocorrência ou não de mudança de conceito.

No entanto, algoritmos não supervisionados carecem de fundamentação teórica para prover garantias à detecção de mudanças de conceitos. A maioria deles compara partições consecutivas usando alguma heurística. Contudo, as divergências não estão necessariamente associadas a mudanças nos dados (e, consequentemente, ao processo), podendo também ser produzidas por instabilidades do algoritmo. Por exemplo, algoritmos como STING (WANG; YANG; MUNTZ, 1997) e o CluStream (AGGARWAL et al., 2003) podem produzir diferentes partições de clustering para as mesmas observações de dados devido à parametrização randômica do K-means utilizado. Este cenário pode aumentar a ocorrência de falsos positivos na detecção de mudanças de conceito.

Enquanto pequenas mudanças são vistas como uma instabilidade natural dos dados, mudanças significativas denotam alterações no processo gerador do fluxo. A detecção destas mudanças - que podem ser abruptas (mais fácil de ser detectada), incrementais ou graduais (TSYMBAL, 2004) - é a principal motivação para os pesquisadores em *concept drift*.

1.2 HIPÓTESE E OBJETIVO

REVISÃO BIBLIOGRÁFICA

2.1 CONSIDERAÇÕES INICIAIS

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

2.2 FLUXOS DE DADOS

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

2.3 MUDANÇA DE CONCEITO

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut

porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

2.3.1 Algoritmos para Detecção de Mudança de Conceito

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

2.3.2 Ferramentas

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

2.4 REDES DE FUNÇÃO DE BASE RADIAL

2.5 TRABALHOS RELACIONADOS

2.6 CONSIDERAÇÕES FINAIS

PLANO DE PESQUISA

3.1 CONSIDERAÇÕES INICIAIS

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

3.2 DESCRIÇÃO DO PROBLEMA

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

3.2.1 Atividades de Pesquisa

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut

porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

3.3 CONSIDERAÇÕES FINAIS

4

EXPERIMENTOS INICIAIS

4.1 CONSIDERAÇÕES INICIAIS

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

4.2 CONFIGURAÇÃO DOS EXPERIMENTOS

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

4.3 MÉTODO DE PETTITT

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut

porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

4.4 REDES DE FUNÇÃO DE BASE RADIAL

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

4.5 CONSIDERAÇÕES FINAIS

REFERÊNCIAS BIBLIOGRÁFICAS

AGGARWAL, C. C. et al. A framework for clustering evolving data streams. In: *Proceedings of the 29th International Conference on Very Large Data Bases - Volume 29*. VLDB Endowment, 2003. (VLDB '03), p. 81–92. ISBN 0-12-722442-4. Disponível em: \(\http://dl.acm.org/citation.cfm?id=1315451.1315460 \).

Ang, H. H. et al. Predictive handling of asynchronous concept drifts in distributed environments. *IEEE Transactions on Knowledge and Data Engineering*, v. 25, n. 10, p. 2343–2355, Oct 2013. ISSN 1041-4347.

GAMA, J. a. et al. A survey on concept drift adaptation. *ACM Comput. Surv.*, ACM, New York, NY, USA, v. 46, n. 4, p. 44:1–44:37, mar. 2014. ISSN 0360-0300. Disponível em: $\langle \text{http://doi.acm.org/}10.1145/2523813 \rangle$.

TSYMBAL, A. The Problem of Concept Drift: Definitions and Related Work. [S.l.], 2004.

WANG, W.; YANG, J.; MUNTZ, R. R. Sting: A statistical information grid approach to spatial data mining. In: *Proceedings of the 23rd International Conference on Very Large Data Bases.* San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 1997. (VLDB '97), p. 186–195. ISBN 1-55860-470-7. Disponível em: \(\http://dl.acm.org/citation.cfm? \) id=645923.758369\(\http://dl.acm.org/citation.cfm? \)