

Uso de Redes de Função de Base Radial e Cadeias de Markov para detecção online de mudanças de conceito em fluxos contínuos de dados

Discente: Ruivaldo Neto

Orientador: Ricardo Rios

Universidade Federal da Bahia

Departamento de Ciência da Computação

Programa de Pós-Graduação em Ciência da Computação

Contato: rneto@rneto.dev

16 de Dezembro de 2019

1. Introdução
2. Fundamentação Teórica
3. RBFChain
4. Experimentos
5. Conclusões e Trabalhos Futuros

Introdução

- Avanços tecnológicos recentes contribuíram para um aumento exponencial no volume de dados produzidos por sistemas computacionais [2].

- Avanços tecnológicos recentes contribuíram para um aumento exponencial no volume de dados produzidos por sistemas computacionais [2].
- Parte significativa dos dados é produzida através de Fluxos Contínuos de Dados (FCDs): sequências ininterruptas e potencialmente infinitas de eventos [1].

- Avanços tecnológicos recentes contribuíram para um aumento exponencial no volume de dados produzidos por sistemas computacionais [2].
- Parte significativa dos dados é produzida através de **Fluxos Contínuos de Dados (FCDs)**: sequências **ininterruptas** e **potencialmente infinitas** de eventos [1].
- FCDs estão presentes em diversos domínios de aplicação:
 - Monitoramento de tráfego;
 - Gestão de redes de telecomunicação;
 - Análise do Mercado Financeiro;
 - Detecção de intrusos.

- Técnicas de **Aprendizado de Máquina (AM)** têm sido aplicadas para extrair informações úteis de grandes conjuntos de dados.

- Técnicas de **Aprendizado de Máquina (AM)** têm sido aplicadas para extrair informações úteis de grandes conjuntos de dados.
- Cenários com FCDs limitam a aplicação de técnicas de AM, pois impõem restrições de tempo de resposta, de uso dos recursos computacionais e apresentam comportamento **não estacionário**.

- Técnicas de **Aprendizado de Máquina (AM)** têm sido aplicadas para extrair informações úteis de grandes conjuntos de dados.
- Cenários com FCDs limitam a aplicação de técnicas de AM, pois impõem restrições de tempo de resposta, de uso dos recursos computacionais e apresentam comportamento **não estacionário**.
- Em cenários não estacionários, o contexto do processo gerador e/ou a distribuição dos dados podem sofrer alterações (**mudanças de conceito**) ao longo do tempo.

- Técnicas de **Aprendizado de Máquina (AM)** têm sido aplicadas para extrair informações úteis de grandes conjuntos de dados.
- Cenários com FCDs limitam a aplicação de técnicas de AM, pois impõem restrições de tempo de resposta, de uso dos recursos computacionais e apresentam comportamento **não estacionário**.
- Em cenários não estacionários, o contexto do processo gerador e/ou a distribuição dos dados podem sofrer alterações (**mudanças de conceito**) ao longo do tempo.
- A ocorrência de **mudanças de conceito** (*concept drifts*) pode impactar a acurácia da técnica aplicada.

- A atualização periódica de modelos, apesar de computacionalmente ineficiente, foi utilizada como estratégia para mitigar a perda de acurácia causada por tais mudanças.

- A atualização periódica de modelos, apesar de computacionalmente ineficiente, foi utilizada como estratégia para mitigar a perda de acurácia causada por tais mudanças.
- Visando obter soluções computacionalmente eficientes e com maior precisão, pesquisadores propuseram novos métodos de detecção de mudança de conceito baseados em monitoramento.

- Entretanto, os métodos disponíveis na literatura ainda apresentam limitações ao serem aplicados em cenários com FCDs [1]:

- Entretanto, os métodos disponíveis na literatura ainda apresentam limitações ao serem aplicados em cenários com FCDs [1]:
 - Necessidade de rotulação;
 - Eficiência computacional (tempo de resposta e uso de recursos).

- Visando superar essas limitações, este trabalho propõe um novo método de detecção de mudanças de conceito baseado em Redes de Função de Base Radial (redes RBF) e Cadeias de Markov;

- Visando superar essas limitações, este trabalho propõe um novo método de detecção de mudanças de conceito baseado em **Redes de Função de Base Radial (redes RBF)** e **Cadeias de Markov**;
- O método proposto se diferencia por detectar mudanças em tempo de execução, de forma computacionalmente eficiente e independente de rótulos.

Fundamentação Teórica

- A:

- A:
 - A1;
 - A2.

- A:
 - A1;
 - A2.
- B

RBFCChain

- A:

- A:
 - A1;
 - A2.

- A:
 - A1;
 - A2.
- B

Experimentos

- A:

- A:
 - A1;
 - A2.

- A:
 - A1;
 - A2.
- B

Conclusões e Trabalhos Futuros

- A:

- A:
 - A1;
 - A2.

- A:
 - A1;
 - A2.
- B



C. C. Aggarwal.

Data Streams: Models and Algorithms (Advances in Database Systems).

Springer-Verlag, Berlin, Heidelberg, 2006.



M. Zwolenski and L. Weatherill.

The digital universe rich data and the increasing value of the internet of things.

Australian Journal of Telecommunications and the Digital Economy,
2, 10 2014.